

# Markov Logic Network

## Markov property

- 无记忆性，下一状态的概率分布今取决于当前状态（未来只和现在相关，和过去无关），即

$$p(x_{n+1} = s_{n+1} | x_n = s_n, x_{n-1} = s_{n-1}, \dots, x_1 = s_1) = p(x_{n+1} = s_{n+1} | x_n = s_n)$$

- 明天的天气，下一时刻车站人数
- 不严谨，但计算高效

## Markov Chain

- 定义
  - 一组随机变量  $X = \{X_1, X_2, \dots, X_n\}$ ，每个随机变量的取值都在可数集内  $X_i = s_i, s_i \in S$ ，如果随机变量的条件概率满足马尔可夫性质

$$p(x_{n+1} = s_{n+1} | x_n = s_n, x_{n-1} = s_{n-1}, \dots, x_1 = s_1) = p(x_{n+1} = s_{n+1} | x_n = s_n)$$

则  $X$  成为马尔可夫链，可数集  $S$  称为状态空间。

## Markov Network

- 定义
  - 马尔可夫网是用来刻画一组随机变量  $X = \{X_1, X_2, \dots, X_n\}$  联合分布的模型，它由一个无向图  $G$  和一组势函数组成。
    - 每个随机变量对应  $G$  上的一个节点
    - $G$  上的每个团都有一个势函数，势函数是从团的状态集到正实数集的映射
- 联合概率分布

$$P(X = x) = \frac{1}{Z} \prod_k \phi_k(x_{\{k\}})$$

其中  $\phi_k$  就是势函数， $x_{\{k\}}$  表示第  $k$  个团的状态（就是团中每个节点（随机变量）的取值）， $Z$  是归一化常数， $Z = \sum_x \prod_k \phi_k(x_{\{k\}})$ ，表示所有状态的下的团势能乘积和

- 对数形式

$$P(X = x) = \frac{1}{Z} \exp\left(\sum_j \omega_j f_j(x)\right)$$

其中  $\omega_i$  为第  $i$  个团的权重， $f_i$  是团特征函数

- 马尔可夫性质
  - 从联合概率分布公式可以看出，某个点的概率分布只和它的相邻节点相关，即只和包含它的团的状态相关。因为这个点相邻节点的取值会影响到包含它的团的特征函数的取值。

## Markov Logic Network

- 一阶逻辑

## Syntax

*variables*  $x, y, z, \dots$

*constants*  $a, b, c, \dots$

*functions*  $f, g, h, \dots$

*terms* variables, constants, or n-ary function applied to n terms as arguments

*predicates*  $p, q, r, \dots$

*atom*  $\top, \perp$ , or n-ary predicate applied to n terms

*literal* atom or its negation

## Syntax cont.

*formula* literal, application of a logical connective  $\{\neg, \wedge, \vee, \rightarrow, \leftrightarrow\}$  to formulae, or application of a *quantifier* to a formula

### ► Quantifiers

► Existential:  $\exists x. F[x]$   
“there exists an  $x$  such that  $F[x]$ ”

► Universal:  $\forall x. F[x]$   
“for all  $x$ ,  $F[x]$ ”

ground term: 闭项, 基本项, 不包含变量的项  $f(t_1, t_2)$

ground atom: 闭原子, 谓词参数是闭项的原子  $R(f_1(t_1), f_2(t_1, t_2))$

ground formula: 闭公式, 原子是闭原子的公式  $R_1(f_1(t_1), f_2(t_1, t_2)) \wedge R_2(f_1(t_1), f_2(t_1, t_2))$

- 马尔可夫逻辑网

定义 1<sup>[37]</sup>. Markov 逻辑网  $L$  是一组二元项  $(F_i, \omega_i)$ , 其中  $F_i$  表示一阶逻辑规则,  $\omega_i$  是一个实数. 这组二元项  $(F_i, \omega_i)$  与一组有限常量集  $C = \{c_1, c_2, \dots, c_n\}$  一起定义了一个 Markov 网  $M_{L,C}$ :

- (1)  $L$  中的任意闭原子 (ground atom) 都对应了  $M_{L,C}$  中的一个二值节点. 若此闭原子为真, 则对应的二值节点取值为 1; 若为假, 则取值为 0.
  - (2)  $L$  中的任意闭规则 (ground formula) 都对应着一个特征值, 若此闭规则为真, 则对应的特征值为 1; 若为假, 则特征值为 0. 并且, 这个特征值的权重为二元项中该规则  $F_i$  对应的权重  $\omega_i$ .
- 这里规则的权重  $\omega$  表示满足规则世界和不满足规则世界的差异性,  $\omega$  越大, 差异越大.
    - 比如  $A \rightarrow B$ , 满足该规则的世界有  $\{(T,T), (F,T), (F,F)\}$ , 不满足的世界有  $\{(T,F)\}$ ,  $\omega$  越大, 表示取到满足世界的可能性越大, 不满足的可能性越小 (但不代表不可能)。
    - 当然, 如果  $\omega \rightarrow \infty$ , 则不满足世界的可能性为 0, 表示不可能发生. 和强逻辑是等价的
  - 马尔可夫逻辑网其实就是生成马尔可夫网的模板
  - 马尔可夫逻辑网结合常量集合  $C$  生产的马尔可夫网结构:
    - 任意闭原子对应一个节点
    - 当两个节点表示的闭原子出现在同一规则中, 则他们之间有条边
      - 因此出现在同一闭规则的闭原子节点构成一个团, 团的权重就是规则的权重
  - 举例

Table 1 A simple example of Markov logic network<sup>[37]</sup>

表 1 一个简单的 Markov 逻辑网实例<sup>[37]</sup>

Proposition	First-Order logic	Clausal form	Weight
Smoking causes cancer.	$F_1: \forall x, Sm(x) \Rightarrow Ca(x)$	$\neg Sm(x) \vee Ca(x)$	1.5
If two people are friends, either both smoke or neither does.	$F_2: \forall x \forall y, Fr(x,y) \Rightarrow (Sm(x) \Leftrightarrow Sm(y))$	$\neg Fr(x,y) \vee Sm(x) \vee \neg Sm(y)$	1.1
		$\neg Fr(x,y) \vee \neg Sm(x) \vee Sm(y)$	1.1

给定常量集合  $C = \{A, B\}$ , 则马尔可夫网  $M_{L,C}$ . 可以看出, 网络大小和参数最多谓词的参数数量, 常量集大小呈指数相关, 会非常大。




Fig. 1 An example of ground Markov network<sup>[37]</sup>

- 联合概率分布

$$P(X = x) = \frac{1}{Z} \exp \left\{ \sum_i \omega_i n_i(x) \right\} = \frac{1}{Z} \prod_i \phi_i(x_{\{i\}})^{n_i(x)}$$

其中 $\omega_i$ 表示规则(公式) $F_i$ 的权重,  $n_i(x)$ 表示公式 $F_i$ 在状态 $x$ 下, 为真的闭公式的个数

## 举例说明和一阶逻辑的关系

$L = \{(\forall x R(x) \rightarrow S(x), \omega)\}$ ,  $C = \{A\}$ .

## 权重学习

类似于线性回归中的梯度下降算法 ( $y = wx + b$ 学习( $w, b$ ))

$x$ 为试验样本

$$\frac{\partial}{\partial w_i} \log P_w(X=x) = n_i(x) - \sum_{x'} P_w(X=x') n_i(x')$$

## 推理

- 最大可能性问题

最大可能性问题是概率图模型推理中的重要内容,其基本过程可表述为:给定证据变量集 $x$ ,求变量集 $y$ 最可能处于的状态,即求

$$\max_y P(y|x) \quad (4)$$

在 Markov 逻辑网中,结合公式(3),则问题转化为求

$$\max_y \sum_i w_i n_i(x, y) \quad (5)$$

其中, $w_i$ 表示从句 $i$ 的权重, $n_i(x, y)$ 表示从句 $i$ 的闭从句的真值数量.

因此,计算最大可能性问题可转换为典型的最大化带权的可满足性问题,即寻找一组变量的赋值,使得所有

- 条件概率

则 $F_2$ 取值为真时,规则 $F_1$ 取值为真的概率为

$$P(F_1 | F_2, L, C) = \frac{P(F_1 \wedge F_2 | M_{L,C})}{P(F_2 | M_{L,C})} = \frac{\sum_{X \in \theta_{F_1} \cap \theta_{F_2}} P(X = x | M_{L,C})}{\sum_{X \in \theta_{F_2}} P(X = x | M_{L,C})}$$